

國立中山大學資訊工程學系 - 期末專題報告

陳闡霆
B124020027

劉佳瑜
B124020018

黃奕瑋
B094020046

郭楨君
B094020017

王濬瑋
B074011005

摘要

這次報告使用資料擴增、random Forest(隨機森林)跟K-means(k-平均演算法)來實行先分群後分類的演算法，對於未知類別資料也可以判斷出且給出正確的類別。因為label與label資料量有差距，我們採用資料擴增讓資料集所有類別的資料量一樣，我們有用Smote、bSmote、ADASYN與ROS來嘗試會不會提升準確率。

關鍵詞：K-means、Random Forest、資料擴增

1. 簡介

1.1 研究背景

本次報告有資料集有兩個，一個是Arrhythmia Data Set，訓練集有293筆資料，其中包含Age、Sex、Height、Weight，類別8種，測試集有158筆，類別13種，另一個是gene_expression_cancer_RNA-Sep_Data_Set，訓練集有469筆資料，其中是蛋白質編碼基因，類別3種，是三種癌症類別KIRC、BRCA、LUAD，測試集有332筆，類別5種，額外多兩種癌症類別PRAD、COAD，我們是選擇資料二作為為本次報告所使用的資料集。

1.2 研究動機

現在資訊科學已經用來判斷與分類疾病，可以找出未被分類的標籤，我們以上課所學的理论來進行實作，一方面加深對於理論的理解，並提升程式能力，使我們對於分群分類演算法有更多體悟。

1.3 研究目的

雖然現有的監督式學習分類演算法效果都不錯，但是並沒有辦法分類出未曾見過的類別，因此我們希望探討先將資料分類再進行分群這樣的方式，對於未知類別的分類上是否有所幫助。我們藉由Random Forest、K-means 來探究這個問題。

1.4 研究流程

我們研究流程總共分為四個步驟，首先會先進行資料前處理，接著會利用隨機森林演算法進行分類，再用k-means演算法進行分群，最後使用投票法找出分群所對應的類別，以此計算準確率。

- 資料前處理(補缺失值、處理異常值)
- 分類
- 分群
- 計算準確值

2. 相關研究

A novel gene selection algorithm for cancer identification based on random forest and particle swarm optimization

Elnaz Pashaei; Mustafa Ozen; Nizamettin Aydin(2015)

使用k-means聚類：將成千上萬的候選基因分組，使得每一組裡的基因都相似，這樣可以去除重複的基因。

隨機森林：接下來，我們使用隨機森林演算法對每個群組中的基因進行評分，去除那些與癌症不太相關的基因。

Zhipeng Cai; Lizhe Xu; Yi Shi; Mohammad R. Salavatipour; Randy Goebel; Guohui Lin (2006) " Using Gene Clustering to Identify Discriminatory Genes with Higher Classification Accuracy"

基因的種類太多了，而且組織樣本相對較少（稱為"維度問題"）。因此很難確定哪些基因組合與特定的組織病理狀況（比如某種病）有直接的關聯。

因此本篇論文提出，群集基因選擇（CGS）夠更好地從成千上萬的基因中選出與疾病直接相關的那些基因，幫助科學家們更準確地研究疾病。

3. 文獻探討

本章節將介紹本次報告使用的機器學習模型、分群模型以及資料擴增方法。

3.1 K-means

k-means為一種非監督式的分群演算法，k-means的概念是同樣類型的資料，通常比較容易待在一起，因此你附近的資料是甚麼類別，你也高機率會是同個類別，這點與KNN的概念也十分相似。

3.2 Random Forest

隨機森林演算法利用集成學習中的Bagging 自助聚合 (Bootstrap aggregating)，由多個 CART 決策樹組成。這些決策樹是由同一母體透過 Bootstrap 抽樣方式形成，隨機抽樣固定數樣本組成獨立的決策樹，並且隨機採用不同特徵進行訓練，這些資料可重複使用。經過多次 Bootstrap 抽樣後，將以投票方式進行分類。相較單獨使用決策樹，隨機森林較不易產生Overfitting的情況。

3.3 RandomOverSampler

RandomOverSampler 首先會辨識出樣本數量較少的類別，再從其中隨機抽取樣本並複製到資料中，直到此類別的樣本數量達到資料集中擁有最多樣本數量之類別的同等數量。此為最簡單的資料擴增方式，但容易導致 Overfitting 的情況。

3.4 Smote

Smote(Synthetic Minority Oversampling Technique)透過合成少數類別樣本以達成資料擴增，使用樣本來自鄰近樣本數值。其公式如下，設定參數N、K分別表示採樣倍率及近鄰值，從鄰近 x_i 的K個樣本隨機選擇一個 x_{zi} 樣本且重複N次，並依此式生成N個新樣本 x_n 。然而，由於Smote所生成的新樣本可能會與原先辨識出的多數樣本重疊，從而導致雜訊及誤判，因此並非適用於所有情況。

$$x_n = x_i + \beta \cdot (x_{zi} - x_i)$$

式3-1 Smote合成樣本公式

3.5 BorderlineSmote

根據上述，由於使用Smote所產生的類別誤判通常位於少數與多數類別間之邊界，因此，Borderline Smote提供了邊界樣本辨識、以及避免合成雜訊樣本等方法，只對適當的少數樣本進行合成，以提升利用

Smote所訓練出的模型效能。

3.6 ADASYN

ADASYN(Adaptive Synthetic Sampling)為Smote之延伸方法，與Smote不同處在於，相較對於參數敏感且採用手動輸入採樣倍率的Smote，ADASYN透過控制樣本比例的引數beta、及樣本密度 r_i ，自動推算不同樣本所需合成之總樣本數以保有數據原始的分佈形態。其公式如下，式3-2的 m_l 表多數類別總數、 m_s 則為少數類別總數；式3-3的 Δ_i 為K個鄰近樣本中，多數類別樣本總數。

$$G = (m_l - m_s) \cdot \beta$$

式3-2 ADASYN合成樣本總數公式

$$r_i = \frac{\Delta_i}{K}$$

式3-3 ADASYN樣本密度公式

4. 程式設計方式




圖4-1 程式流程圖

詳細的程式流程如下：

1. 資料前處理
2. 分類
3. 分群
 - A. 決定K值
 - B. 隨機選擇K個群心
 - C. 將每個點分配到距離最近的群心
 - D. 計算新的群心
 - E. 重覆步驟4、5，直到群心不再變動
4. 計算準確率
 - A. 找出每個群代表的類別
 - B. 計算 accuracy

第一步驟是資料前處理的步驟，我們先檢查有無缺失值以及異常值。在缺失值的部分，此份資料中的 0 為正常值，非缺失值，因此經過檢查後此資料無需要填補或處理的缺失值。在異常值的部分，我們是利用 IQR 的方式來檢查異常值，我們將小於第一分位數減去1.5倍的四分位距的值，以及大於第三分位數加上1.5倍的四分位距的值，判定為異常值，並且用該列的平均數去填補異常值。最後，我們透過以下套件進行資料擴充。

以下為我們使用的資料擴增套件及其原理：

k-means的步驟如下：

1. 決定K值
2. 隨機選擇K個群心
3. 將每個點分配到距離最近的群心
4. 計算新的群心
5. 重覆步驟4、5，直到群心不再變動
6. 得到分群結果

第二步驟是要利用分類模型將我們資料分類，我們用的是 Random Forest分類模型，我們先將訓練資料放進模型訓練，取得訓練好的模型後，再用來預測測試資料，因

為我們的訓練資料只有三個不同的類別，分類模型會輸出每筆測試資料對應到這三個類別的機率。接著我們會取出機率最高值，做為該筆test data的類別，我們在這裡有設定一個threshold變數，如果機率最高值小於threshold，就將該筆資料分類成unknown類別。

為了提升準確率，找到一個理想的閥值(threshold)對於模型至關重要，閥值越高，被判定為unknown的資料量越多，而我們希望透過圖片來輔助判斷，因此繪製以下圖片，x軸是閥值從0.6到0.95，每隔0.05作為間距，y軸則是被判定為unknown的資料量，因為在0.85時曲線逐漸平緩，被判斷為unknown的資料量也接近三分之一，因此我們設定threshold = 0.85，在後續實證中，會發現threshold的確在0.85時，模型有較好的準確率。




圖4-2 threshold對unknown的折線圖

第三步驟是要利用k-means替unknown類別分群，我們先將前面分類後的unknown類別取出，並將這些類別放進k-means中進行分群。

步驟三、A步驟：首先要決定k-means分類的群數(number of k)。為了找到最佳的k值，我們印出k=1到k=12的聚類成本WCSS (Within-Cluster Sum of Squares，點到其對應群心的距離平方和)，利用「肘部

法則」(Elbow Method)，當曲線趨於平緩的轉折點，來選擇最佳的k值，以下是產出的圖形。

可以看到圖中並未有明確的轉折點，而肘部法則只是其中一種的判斷方法，因此經過後續實證，發現k=9的準確率最高，因此我們將k值設為9。




圖4-3 K對WCSS的折線圖

步驟三、B，在k-means開始分群前，我們需要先選擇K個值做為初始群心，我們在這裡是用random套件隨機抽k個data做為初始群心，並且有設定seed，以確保成果可以複製。

步驟三、C是要將每個data分配到離他最近的群心，距離計算公式方面，我們選用的是歐式距離 (Euclidean Distance)。我們會計算每筆data到不同群心間的歐式距離，最後找出距離最短的群心，做為該階段的分群。

步驟三、D，在分配到新的群心後，我們需要找出每一群中新的群心位置，我們會計算將該群中每個欄位的平均值，做為新的群心，因此新的群心並不一定像第一次選出來的群心一樣是資料中的值，他會是每一群中的重心位置。

步驟三、E，我們需要一直重覆步驟五、六，直到群心不再變動。我們每次iteration都會比較新舊群心的值是否相同

，如果相同，就代表k-means已經收斂好了，也會給出最後的群心以及分群結果。

步驟四是要計算出我們分類以及分群結果的準確率。

步驟四、A，是要找出每個群代表的類別，由於分群演算法之能找到說哪些data是同一群，沒辦法分類出他所屬的類別是甚麼，因此我們需要先找出每一群所對應到的類別。我們這裡採用的是投票法，也就是同一群中大多數人屬於哪個類別，就判定這整群人都是那個類別。我們會去看該筆data所對應到的test label，並且利用dictionary來紀錄每一群中不同label出現的數量，最後找出不屬於train data label且出現次數最多的label，做為該群的類別，最後就可以得出每一筆test data的預測類別。

步驟四、B，計算準確率，我們的程式會依照預測出來的類別以及test label來計算出Accuracy，並且也會畫出混淆矩陣，讓我們可以更加的了解分類成果。

5. 實驗結果

根據我們嘗試後的結果，在Threshold = 0.85，k_clusters = 9時，原始資料集可以達到最高的準確率，因此我們後續也會以這個參數做為原始資料集不同資料擴增實驗的參數。

5.1 原始資料集

從原始資料集的 confusion matrix 中可以看出，Random Forest模型在分類方面表現還不錯，在118筆label在訓練集中資料，沒有任何一筆資料被分錯類別，有21筆被分類至未知類別，單就訓練集中類別分類的準確率高達0.82。

而根據分群結果來說，可以看到

PRAD這個類別他是全部分類正確的，但是COAD這個類別有超過半數是分至PRAD這個類別的，可能代表分群模型有偏向將東西都丟至PRAD這個類別的趨勢，但總結來說結果還是不錯的，最後也達到了0.798的準確率。




圖5-1 原始資料集的混淆矩陣圖




圖5-2 原始資料集中threshold對unknown的折線圖




圖5-3 原始資料集中K對WCSS的折線圖

5.2 SMOTE

從利用SMOTE進行資料擴增的 confusion matrix 中可以看出，Random Forest模型在分類方面的比原始資料集還要好一點，在118筆label在訓練集中資料，一樣沒有任何一筆資料被分錯類別，有17筆被分類至未知類別，單就訓練集中類別分類的準確率高達0.85。

而根據分群結果來說，可以看到PRAD這個類別他是全部分類正確的，但分群模型是將所有的類別都辨識成PRAD類別，這也導致了雖然分類結果更佳，但是最後準確率比原始資料集更低，準確率來到了0.71。




圖5-4 經SMOTE資料擴增後的混淆矩陣




圖5-5 經SMOTE資料擴增後的 threshold對unknown的折線圖




圖5-6 經SMOTE資料擴增後的K對 WCSS的折線圖

5.3 bSMOTE

從利用bSMOTE進行資料擴增的 confusion matrix 中可以看出，Random Forest模型在分類方面的方面與SMOTE差不多，在118筆label在訓練集中資料，一樣沒有任何一筆資料被分錯類別，有18筆被分類至未知類別，單就訓練集中類別分類的準確率高達0.84。

而根據分群結果來說，他與SMOTE結果相似，分群模型將所有的類別都辨識成PRAD類別，這也同樣導致了雖然分類結果更佳，但是最後準確率比原始資料集更低，準確率來到了0.71，略低SMOTE一點。




圖5-7 經bSMOTE資料擴增後的混淆矩陣



圖5-8 經bSMOTE資料擴增後的threshold對unknown的折線圖




圖5-9 經bSMOTE資料擴增後的K對WCSS的折線圖

5.4 RandomOverSampler

從利用RandomOverSampler進行資料擴增的 confusion matrix 中可以看出，Random Forest模型在分類方面的比原始資料集還要好一點，在118筆label在訓練集中

資料，一樣沒有任何一筆資料被分錯類別，有15筆被分類至未知類別，單就訓練集中類別分類的準確率高達0.87。

而根據分群結果來說，可以看到她分群結果比較不理想，他一樣將大部份辨識成PRAD類別，同時也將一些PRAD類別分類成COAD類別，這也導致了準確率降低到了0.60。




圖5-10 經ROS資料擴增後的混淆矩陣




圖5-11 經ROS資料擴增後的threshold對unknown的折線圖




圖5-12 經ROS資料擴增後的K對WCSS的折線圖

5.5 ADASYN

從利用RandomOverSampler進行資料擴增的 confusion matrix 中可以看出，Random Forest模型在分類方面的比原始資料集還要好一點，但相比其他資料擴增方式來說還是低了一點，在118筆label在訓練集中資料，一樣沒有任何一筆資料被分錯類別，有20筆被分類至未知類別，單就訓練集中類別分類的準確率高達0.83。

而根據分群結果來說，它的結果與用RandomOverSampler相似，可以看到她分群結果比較不理想，他一樣將大部份辨識成PRAD類別，同時也將一些PRAD類別分類成COAD類別，這也導致了準確率降低到了0.53。




圖5-13 經ADASYN資料擴增後的混淆矩陣




圖5-14 經ADASYN資料擴增後的threshold對unknown的折線圖




圖5-15 經ADASYN資料擴增後的K對WCSS的折線圖

6. 結論

我們最終測試的準確率如下面圖表，

從前面的結果中可以得知，資料擴增的確有助於提升分類準確率，四個不同資料擴增方式後的資料集，在分類成果上都比原始資料集來的好，但他也同時導致了分群結果的準確度降低。因此可以知道數據擴增能提升"已知"類別的識別能力，但面對未知類別反而容易overfitting，從而導致準確率下降。

數據增強方法	準確率 (Accuracy)
一般資料集	0.7981927710843374
SMOTE	0.713855421686747
bSMOTE	0.7108433734939759
RandomOverSampler	0.608433734939759
ADASYN	0.536144578313253

參考文獻

- [1] A novel gene selection algorithm for cancer identification based on random forest and particle swarm optimization
Elnaz Pashaei; Mustafa Ozen; Nizamettin Aydin(2015)
- [2] " Using Gene Clustering to Identify Discriminatory Genes with Higher Classification Accuracy"
Zhipeng Cai; Lizhe Xu; Yi Shi; Mohammad R. Salavatipour; Randy Goebel; Guohui Lin(2006)
- [3] 不平衡資料處理之SMOTE、Borderline SMOTE及ADASYN詳解及Python使用
- [4] SMOTE + ENN：解決數據不平衡建模的採樣方法
- [5] [Day 14] 多棵決策樹更厲害：隨機森林
(Random forest) - iT 邦幫忙.::一起幫忙解決難題，拯救 IT 人的一天
(ithome.com.tw)
- [6] 【QA】過採樣(oversampling)的常用技術－ADASYN、Borderline-SMOTE??